

Informe técnico — Equipo RMSE

Hackathon 2026 · AI WEEK, Universidad de los Andes

Integrantes: Andrés Chaparro, Camilo Sánchez, Lucas Mejía

1. Arquitectura del sistema

Nuestro sistema está compuesto por un pipeline con etapas intercambiables, elegidas por configuración. Una pregunta recorre: (1) **lookup directo** de las normas, artículos y sentencias que nombra, con el extractor oficial de citas; (2) **recuperación híbrida** densa y BM25 fusionada con RRF, sobre el corpus sin la relatoría cosechada; (3) **reranker** con tope por tipo de documento; (4) **fusión** en exactamente los 10 pasajes que verá el LLM y que se entregan; (5) **generación** del JSON del formato con guided JSON; (6) **verificación**: elimina toda cita ausente de los 10 pasajes sin volver a llamar al LLM, completa el fundamento con las normas de los pasajes y lleva la respuesta a la extensión del enunciado con oraciones literales de la evidencia; (7) **abstención** decidida por el código.



Figura 1. Recorrido de una pregunta. Si la evidencia es débil, el planner re-planea una vez con tres subconsultas.

El pipeline agéntico agrega un re-planeo con tres subconsultas cuando la evidencia es débil (texto libre, sin lookup y mejor score del reranker < 0,75), como máximo una vez. Todo es determinista y cada pregunta deja su traza (pasajes por consulta, tiempos por etapa, llamadas al LLM).

El corpus (29.124 documentos, 1,54 M de fragmentos) se construye con un pipeline reproducible en `src/ingest/` (resolución de URL validada por contenido, descarga con sha256, un parser por fuente, OCR abierto para PDF escaneados, segmentación y metadatos) y se indexa con `python -m src.index.construir`. Detalle en `CORPUS.md`.

2. Selección de encoder y decoder

Componente	Modelo	Motivo de la elección	Alternativas descartadas
Encoder	BAAI/bge-m3	Denso solo, body-hit@10 0,90, el mejor de los de 1.024 dimensiones junto con arctic; con BM25, lookup y reranker ningún encoder lo supera de forma pareja (benchmark de cinco sobre 66.291 fragmentos)	Qwen3-Embedding-4B (0,95 solo, igual en el pipeline, 33 min de indexado frente a 2,5-9), jina-embeddings-v3 (menos article-hit: 0,53 frente a 0,58), snowflake-arctic-embed-l-v2 (empate), multilingual-e5-large (0,85)
Decoder	Llama-3.1-8B-Instruct	59,03/80 en la muestra, el mejor de cinco decoders abiertos de ≤ 8B en las condiciones del sábado	Ministral-8B (54,89), Qwen3-8B (54,80), Salamandra-7B (48,95), Granite 4.2 8B (38,05)
Reranker	BAAI/bge-reranker-v2-m3	Mismo body-hit y recall que alternativas 2 a 6 veces más lentas	Qwen3-Reranker 0,6B y 4B, bge-reranker-v2-gemma

Configuración de inferencia: Ollama, cuantización q4_K_M, ventana de 16.384 tokens (los prompts reales ocupan 3.400-5.500), temperatura 0 y semilla fija, salida restringida al JSON del formato, tope de tokens por formato. La caché KV se vacía antes de cada llamada para que la

salida no dependa del historial, y el modelo se carga antes de la primera llamada con su propio tiempo límite (en frío tarda 34-60 s). **Tiempo medio: 4,4 s por pregunta** en una RTX 4090.

3. Estrategia de recuperación

Segmentación: leyes y códigos por artículo; sentencias por sección (antecedentes, consideraciones, decisión, votos) más una ficha con ponente, fecha y lo resuelto. Los fragmentos tienen hasta 2.000 caracteres (~500 tokens); un artículo o una sección más larga se parte con su encabezado repetido. Todo fragmento empieza con el nombre citable de su norma, porque el evaluador solo reconoce el respaldo si la cita está en el texto.

Índice: exacto (producto interno sobre la matriz normalizada) más BM25 de bm25s con Snowball español y un tokenizador que conserva "C-355" o "2.2.1.1.1" como un término. Por consulta se toman 50 candidatos de cada recuperador, se fusionan con RRF ($k = 60$), el reranker ordena 40 y quedan **top-k = 10**. El lookup aporta hasta 4 pasajes de lo nombrado en la pregunta, que van primero.

Tope por tipo: como máximo 3 fragmentos de sentencia entre los 10 (6 si la pregunta pide jurisprudencia), ningún salvamento o aclaración de voto (2 si la pregunta los pide) y 2 de decretos únicos o circulares; los documentos que la pregunta nombra no cuentan para el tope.

Relatoría solo por número: la relatoría completa de la Corte Constitucional es cerca del 97 % de los fragmentos. En la búsqueda general desplazaba a la norma aplicable aun cuando estaba entre los candidatos (total de la muestra 52,40); excluida de la búsqueda general y accesible por número, el total volvió a 58,62 y las 60 sentencias de una sonda de preguntas que las nombran llegaron todas a la evidencia.

Cifras vigentes: cuando la pregunta trae montos, UVT o auxilio de transporte, el artículo que fija la cifra de 2026 ocupa el último de los 10 lugares.

4. Verificación de citas y abstención

Cada cita del JSON se extrae con scripts/citations.py y se compara, por cuerpo normativo, con las normas que el mismo extractor lee en el texto de los 10 pasajes entregados; la que no esté se elimina del texto sin volver a llamar al LLM, y una aserción impide entregar una respuesta con citas sin respaldo (0 en la muestra). Después, el fundamento (justificación en cerradas, referencia legal en semiabiertas) se completa con las normas de las que son los pasajes.

Abstención: las cerradas nunca se abstienen. En texto libre el sistema se abstiene si no hay pasajes o si el LLM no encuentra la respuesta en ellos; si la evidencia es débil, antes de abstenerse re-planea una vez con subconsultas.

5. Resultados sobre las preguntas de muestra

Componente	Puntos	Posibles
Exactitud en cerradas (12 de 15)	16,00	20
Calidad de citación (recall 0,918; 0 citas sin respaldo)	18,37	20
Abstención calibrada	9,30	10
Total automático sin RAGAS	43,67	50
Corrección RAGAS (media de dos juicios: 0,461)	13,82	30
Total automático con RAGAS	57,49	80

Análisis de los errores más frecuentes:

- **Cerradas:** la 528 pide clasificar una cuantía de 30 millones; el modelo tiene el artículo del CGP y el salario mínimo de 2026 y aun así no hace la conversión. La 647 tiene el Código Civil a la vista pero la respuesta esperada es doctrinal. La 671 (reglas de desempate en convenios de doble imposición) no tiene fuente en el corpus.
- **Texto libre:** las pérdidas de RAGAS vienen sobre todo de conclusiones que contradicen la referencia con la norma correcta a la vista (563, 879) y de conocimiento ausente (142: la sentencia de unificación del Consejo de Estado sobre deducibilidad; 697: doctrina arbitral). Completar la extensión mínima alarga las semiabiertas (96 palabras de mediana frente a 78 de la referencia) y baja la corrección juzgada (limitación 2).
- **Citación:** de 49 cuerpos de referencia faltan 4: dos no llegan a los 10 pasajes (60, 1073) y dos están en ellos pero la respuesta no los cita (51, 253).

6. Limitaciones

1. **El razonamiento del modelo de 8B es el límite principal.** Con la evidencia correcta, a veces concluye lo contrario o calcula mal; pedirle razonar antes de responder no lo corrigió y los pasos de autoevaluación con el mismo modelo empeoran según la literatura revisada.
2. **Cumplir la extensión del enunciado cuesta.** El modelo responde con menos oraciones de las exigidas; completarlas con texto literal de la evidencia baja la corrección juzgada cerca de 1,1 puntos en la muestra.
3. **Jurisprudencia sin nombrar.** La relatoría completa solo entra cuando la pregunta nombra la sentencia; un "precedente sobre X" no la consulta (hay una variante implementada y apagada).
4. **Artículo exacto.** En 8 de las 19 preguntas con artículo de referencia, el artículo no llega a los 10 pasajes, aunque la norma sí.
5. **Huecos y abstención.** Faltan algunas sentencias del Consejo de Estado y de la Corte Suprema, y el umbral de abstención por confianza no está calibrado: el sistema casi nunca se abstiene.
6. **La muestra es pequeña y el juez ruidoso.** Con 35 ítems de texto libre y variaciones de hasta 0,9 puntos entre juicios de una misma entrega, solo las diferencias deterministas o repetidas en varios juicios guiaron las decisiones.